

# 基于 DBN 的故障特征提取及诊断方法研究\*

赵光权,葛强强,刘小勇,彭喜元

(哈尔滨工业大学自动化测试与控制系 哈尔滨 150080)

**摘要:**随着装备日趋复杂化,依靠专家经验或信号处理技术人工提取和选择故障特征变得越来越困难。此外,以 BP 神经网络、SVM 为代表的浅层模型难以表征被测信号与装备健康状况之间复杂的映射关系,且面临维数灾难等问题。结合深度置信网络(DBN)在提取特征和处理高维、非线性数据等方面的优势,提出一种基于深度置信网络的故障特征提取及诊断方法。该方法通过深度学习利用原始时域信号训练深度置信网络并完成智能诊断,其优势在于能够摆脱对大量信号处理技术与诊断经验的依赖,完成故障特征的自适应提取与健康状况的智能诊断,该方法对时域信号没有周期性要求,具有较强的通用性和适应性。在仿真数据集和轴承数据集上进行了故障特征提取和诊断实验,实验结果表明:本文提出的方法能够有效地从原始信号中进行多种工况、多种故障位置和多种故障程度的故障特征提取和诊断,并且具有较高的故障识别精度。

**关键词:**深度置信网络;特征提取;故障诊断;原始数据

**中图分类号:** TP206+.3 TH165+.3 **文献标识码:** A **国家标准学科分类代码:** 510.40

## Fault feature extraction and diagnosis method based on deep belief network

Zhao Guangquan, Ge Qiangqiang, Liu Xiaoyong, Peng Xiyuan

(Department of Automatic Test and Control, Harbin Institute of Technology, Harbin 150080, China)

**Abstract:** As the equipment is increasingly complicated, it is much more challenging to artificially extract and select fault features using expertise and signal processing technology. In addition, traditional shallow architectures, i. e., BP neural network, SVM, are not capable enough at learning the complex nonlinear relationships between equipment health status and its represented signals. Deep belief network (DBN) has unique advantages in feature extraction, high-dimensional and nonlinear data processing. Hence, a novel fault feature extraction and diagnosis method are proposed based on deep belief network. Deep neural network can be directly trained using original time domain signal and utilized for smart fault diagnosis. This proposed method can adaptively extract the fault features and automatically identify machinery health conditions, overcoming the dependence on massive signal processing technologies and expertise. Moreover, periodic time domain signals are not required, which makes this method with high applicability and generality. The effectiveness of the proposed method is validated using datasets from simulations and bearings. The diagnostic results prove that the proposed method is able to conduct fault feature extraction and diagnosis effectively under various operating conditions, fault locations and levels from the raw signals to obtain superior diagnosis accuracy.

**Keywords:** deep belief network; feature extraction; fault diagnosis; raw data

## 1 引言

随着科技的发展,航空、航天、工业等领域的机电设备日趋复杂化、智能化、综合化,并且其运行工况和工作环境也愈加复杂多变,导致其维护和保障成本越来越高,

同时由于组成环节和影响因素的增加,发生故障的几率逐渐加大<sup>[1-2]</sup>,因此对复杂装备系统进行准确、有效的故障诊断成为提高系统安全性和可靠性,并降低维护成本的有效途径。故障诊断技术是一门多学科交叉的综合性技术,对重大设备的故障预防和维修起到至关重要的作用。伴随着机器学习等技术的发展,故障诊断已成为多

种方法综合的模式识别过程<sup>[3]</sup>,其过程一般包括数据采集、特征提取、特征选择和融合、健康状况识别4个步骤,其中特征提取是一个关键步骤,特征提取的好坏很大程度上决定着故障诊断的性能。故障诊断经过几十年的发展,许多不同的故障特征提取方法被提出,如统计分析、自回归模型(autoressive model, AR)、小波分析、经验模式分解和奇异值分解<sup>[4-5]</sup>。然而,上述故障特征提取方法一般都需要进行复杂的数学运算和对要提取的信号有一定理解以及具备丰富的信号处理技术,这对一些简单系统是有效的,但对于一些复杂系统,由于外界环境干扰和内部结构相互影响,传统的故障特征提取方法不足以挖掘出对所有故障类型敏感的特征,有时需要几种故障特征提取方法融合,才能达到一定的效果<sup>[6]</sup>。总的来说,随着装备向复杂化和综合化方向发展,监测系统采集的数据量越来越大<sup>[7]</sup>,传统故障诊断方法由于过度依赖专家诊断经验和需要掌握大量信号处理技术等问题,在面对现代复杂装备时,已经显得有点捉襟见肘。因此,迫切需要研究一种新的方法以适应诊断系统的变化。

最近几年,深度学习作为机器学习领域的一种新兴方法,以其强大的自动特征提取能力在图像、语音识别等领域已经取得了辉煌的成果<sup>[8]</sup>。深度置信网络(deep belief network, DBN)<sup>[9]</sup>作为深度学习的经典算法之一,以其优异的特征提取和训练算法,成功的解决了诸如信息检索、维数约减、故障分类等问题。DBN方法相比较传统的故障诊断方法,主要具有以下几点优势:1)深度学习具有强大的特征提取能力,能从大量数据中自动提取特征,减少了对专家故障诊断经验和信号处理技术的依赖,降低了传统方法中由于人工参与导致特征提取和故障诊断的不确定性;2)通过建立深层模型,能够很好的表征信号与健康状况之间复杂的映射关系,非常适合于大数据背景下多样性、非线性、高维健康监测数据诊断分析需求。因此将深度学习应用到故障诊断领域,具有一定的时效性、实用性和通用性。

自从2013年,Tamilselvan P等人<sup>[10]</sup>第一次把DBN应用到飞机发动机故障诊断以来,已经有越来越多的国内外学者去关注这一领域,并取得不少研究成果。Tran V. T.等人<sup>[11]</sup>把DBN和Teager-Kaiser能量运算算子(Teager-Kaiser energy operation, TKEO)算法融合,在往复压缩机阀门故障诊断中,取得了更高的故障识别率;Shao H等人<sup>[12]</sup>将粒子群优化算法(particle swarm optimization, PSO)算法与DBN算法融合,在旋转轴承先验故障信息缺少的情况下,取得了比较好的识别精度;Li C等人<sup>[13]</sup>提出一种多模式深度支持向量分类(multimodal deep support vector classification, MDSVC)分类的方法,解决了单一振动源下齿轮故障识别精度不高的问题;Jia F等人<sup>[14]</sup>利用深度神经网络(deep neural network, DNN)

直接从旋转轴承的频域信号进行故障特征提取和识别,取得了较好的效果。通过归纳上述文献,虽然DBN已被应用在故障诊断领域,但研究还很不成熟,仍有许多问题亟待解决,主要问题归纳如下:1)仅仅将DBN作为一个分类器,仍然使用传统信号处理方法去提取故障特征,未能充分利用DBN挖掘故障特性的能力;2)利用DBN算法对采集的故障信号进行故障特征提取和健康状况识别时,使用的大都是频域信号,当信号不具有周期性时,此方法将失效,不具有一般性;3)DBN与其他浅层模型的对比研究不够充分。

针对上述问题,本文提出一种基于深度置信网络的故障特征提取及诊断方法,该方法直接从原始时域信号进行故障特征提取和健康状况识别。

## 2 基于深度置信网络的故障诊断方法

人类大脑在接收外部信号时,是通过一个多层的结构来获取数据的规律,这些大脑机理的发现,促使了深度学习的产生和使用。深度置信网络作为深度学习的经典算法之一,能够通过一系列的非线性变换自动从原始数据中提取由低层到高层、由具体到抽象的特征<sup>[15]</sup>。

深度置信网络是由多个限制玻尔兹曼机(restricted Boltzmann machine, RBM)组成的多隐含层神经网络,其核心就是用逐层贪婪学习算法去优化深度神经网络的连接权重,即首先使用无监督逐层训练的方式,有效挖掘待诊断设备中的故障特征,然后在增加相应分类器的基础上,通过反向的有监督微调,优化DBN的故障诊断能力。其中无监督逐层训练通过直接把数据从输入映射到输出,能够学习一些非线性复杂函数,这也是其具备强大特征提取能力的关键所在。

RBM作为DBN模型的基石,在DBN模型构建和训练中,起到至关重要的作用。每个RBM包含一个可视层和一个隐含层,通过RBM的逐层堆叠,DBN模型可从原始数据中逐层提取特征,获得一些高层次表达。RBM中的权重和阈值被持续更新,直到达到最大的迭代次数,关于RBM网络的更新规则推导见文献[16]。

随着各种复杂机电装备的结构和工作环境日趋复杂,传统的以浅层模型为基础的信号处理技术和智能诊断方法已经显得力不从心。本文在分析深度置信网络基本原理的基础上,结合目前故障诊断方法的局限性和深度置信网络的优势,给出基于DBN的故障诊断方法,主要包括以下5个步骤:1)利用传感器获得复杂设备在不同健康状态下的时域监测信号;2)对时域监测信号进行分段(每段的采样点数一致),对分段后的信号进行[0, 1]标准化,并将数据划分为训练集和测试集;3)建立一个多隐含层的DBN模型,根据故障样本维数确定DBN

模型的输入层节点数,使用训练集对 DBN 模型进行无监督逐层训练;4)根据故障类别确定 DBN 模型的输出层节点数,使用 BP 算法对 DBN 模型的权重和阈值进行反向微调;5)利用训练好的 DBN 模型对测试集或待诊断数据进行故障诊断。

由以上步骤可以看出,用 DBN 方法进行故障诊断和其他方法的主要区别为:DBN 方法的故障特征提取和分类器是组合在一起的,具有一定的普适性;本文 DBN 输入的是原始数据,不需要经过复杂的信号处理运算,不会受人为因素干扰,造成识别性能下降;DBN 方法是一种多层模型,相比较传统的浅层诊断方法,可有效避免发生维数灾难和诊断能力不足等问题。

3 基于深度置信网络的特征提取方法

由前面分析可知,特征提取在故障诊断中起到一个关键性的作用,复杂装备故障信号特征提取的好坏决定着最终故障诊断的效果,进而影响最终的预测和维护。传统的故障特征提取方法由于过多的依赖于信号处理技术和专家经验,不适用于日趋复杂的重大装备。

自从 2006 年,Hinton G. E. 等人<sup>[9]</sup>第一次提出深度置信网络时,就证实了其具有强大的特征提取能力,近十年的许多应用,也进一步证实了深度置信网络具有突出的特征提取能力<sup>[8]</sup>。深度置信网络作为一种自我学习的特征提取算法,以其强大的特征提取能力和不需要大量标签数据的参与,在很多应用领域已经被广泛使用。DBN 提取故障特征的过程如图 1 所示。

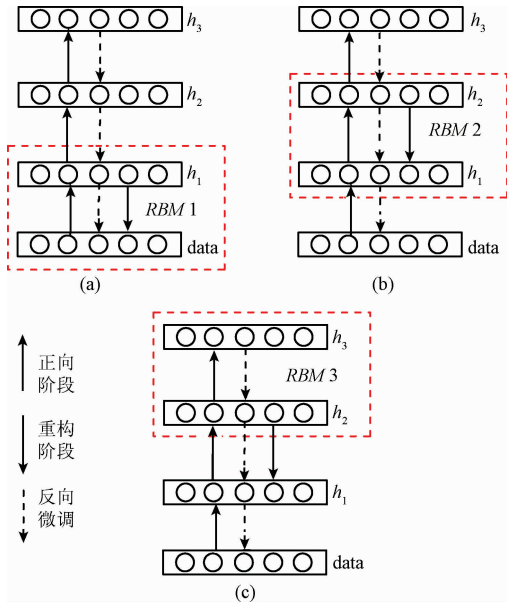


图 1 DBN 逐层提取特征过程

Fig. 1 DBN feature extraction process layer by layer  
万方数据

首先逐层无监督训练 DBN 模型,然后使用反向微调算法对 DBN 模型进行有监督训练,最后将待测数据集输入到训练好的 DBN 模型中,记录每个隐含层的输出向量。故障特征提取步骤如表 1 所示。

表 1 DBN 故障特征提取过程

Table 1 DBN Feature extraction process	
步骤	过程内容
1	定义故障诊断问题和故障类型
2	对故障信号进行[0, 1]标准化处理
3	划分数据集为训练集和测试集
4	初始化 DBN 的相关参数
5	用训练集训练堆叠 RBM
6	测试集输入到已训练的堆叠 RBM 模型中,并记录每个隐含层的输出向量

为了直观看出 DBN 方法从原始数据中提取特征的效果,需要对提取的特征进行可视化,由于原始数据和 DBN 每层提取的特征维数都比较高,不能直接进行观察,因此使用 PCA 方法去减少数据维数,以便更容易看出 DBN 方法的特征提取能力。

4 仿真实验验证

4.1 仿真信号描述

为了验证本文提出的基于 DBN 模型的故障特征提取及诊断方法的性能,使用 3 个带有较大干扰噪声的仿真信号  $x$ 、 $y$  和  $z$  去模拟故障信号<sup>[17]</sup>。这 3 个信号由不同的调幅、调频以及调幅-调频信号混合而成,每个信号都有固定的频率和载波中心,可以模拟故障诊断系统中不同故障设备的固有频率,例如轴承系统中的内圈和外圈故障。根据信号处理知识,正弦信号可以组合成大部分想要的振动信号,因此这 3 个仿真信号能够模拟故障信号去验证基于 DBN 的故障特征提取及诊断方法的性能。为了更贴近实际故障环境,给每个仿真信号加上一定的随机噪声。

仿真信号  $x(t)$  由谐波信号  $x_1(t)$ 、 $x_2(t)$  与随机白噪声  $w$  组成,如式(1)所示。

$$\begin{cases} x_1(t) = 5\cos(20\pi t) + 10\cos(40\pi t) \\ x_2(t) = 15\cos(60\pi t) + 20\cos(80\pi t) \\ w = 20 \cdot \text{randn}(1, n) \\ x(t) = x_1(t) + x_2(t) + w \end{cases} \quad (1)$$

仿真信号  $z(t)$  由调幅调频信号  $z_1(t)$ 、 $z_2(t)$  与随机白噪声  $w$  组成,如式(2)所示。

$$\begin{cases} z_1(t) = 4\sin(25\pi t)\sin(30\pi t) + \sin(40\pi^2 t) \\ z_2(t) = [10 + 5\cos(10\pi t)]\cos[2\pi t + 2\cos(5\pi t)] \\ w = 20 \cdot \text{randn}(1, n) \\ z(t) = z_1(t) + z_2(t) + w \end{cases} \quad (2)$$

仿真信号  $y(t)$  为调幅信号  $y_1(t)$ 、 $y_2(t)$ 、 $y_3(t)$  和  $y_4(t)$  以及随机白噪声  $w$  组成,如式(3)所示。

$$\begin{cases} y_1(t) = 5[1 + \cos(4\pi t)]\cos(20\pi t) \\ y_2(t) = 10[1 + \cos(4\pi t)]\cos(40\pi t) \\ y_3(t) = 15[1 + \cos(4\pi t)]\cos(60\pi t) \\ y_4(t) = 20[1 + \cos(4\pi t)]\cos(80\pi t) \\ w = 20 \cdot \text{randn}(1, n) \\ y(t) = y_1(t) + y_2(t) + y_3(t) + y_4(t) + w \end{cases} \quad (3)$$

首先对这3个信号进行离散化,采样频率为12 800 Hz,采样时间为20 s,将采样后的信号等分为512段,对每段进行线性归一化变换,使其幅值限制在[0,1]内。仿真信号分为512组,每组有500个数据点,3个信号总共包含1 536组样本,则形成1 536个500维的样本空间。随机选取每类信号的60%作为训练样本,剩下的作为测试样本。根据表1描述的相关步骤对仿真信号进行特征提取和识别,本部分DBN模型采用经典的5层模型,节点数为500-300-200-100-3;RBM的最大迭代次数为100,学习率为0.1,动量参数为0.9。

4.2 仿真实验结果

为了验证基于DBN方法的故障特征提取能力,按照如表1所示步骤从原始信号中逐层提取特征,并利用PCA方法提取出这些特征的前2个主成分进行可视化,图2为仿真信号的原始特征可视化。




图2 仿真数据集的原始特征可视化

Fig.2 Visualization of the raw features in simulations

从图2可以看出,3类仿真信号的特征交叉重叠在一块,相互交错很难进行区分。图3给出了利用DBN方法对仿真信号特征提取后的可视化图。




图3 仿真数据集的DBN方法提取特征可视化

Fig.3 Visualization of the extracted features of simulated datasets with DBN

从图3可以看出,同一类别的仿真信号被有效地聚集在一起,不同类别的仿真信号被很好地区分开来。由图2和3的结果对比可以得出,DBN模型能够自适应地从原始时域信号中提取特征。

为了验证基于深度置信网络的故障识别能力,按照第2节所述步骤对仿真信号进行分类识别,并与文献[17]采用的6种传统特征提取+BP分类器的方法进行对比,对比结果如表2所示。表2中的准确率为分类正确的样本数与总样本数的比值。

表2 仿真数据集的诊断结果

Table 2 Diagnostic results of simulated datasets			
方法	准确率(%)	方法	准确率(%)
PCA-BP <sup>[17]</sup>	68.33	ONPE-BP <sup>[17]</sup>	90
LPP-BP <sup>[17]</sup>	76.67	LLTSA-BP <sup>[17]</sup>	88.33
LDA-BP <sup>[17]</sup>	85	多隐层BP算法	83
OLPP-BP <sup>[17]</sup>	91.67	时域信号+DBN	95.55

从表2可看到,利用DBN模型直接从原始时域信号中进行故障识别,识别准确率达到95.55%,优于多隐层反向传播算法的83%,精度提高了约12.55%。将本文提出的方法与基于正交局部保持映射(orthogonal locality preserving projection, OLPP)的特征提取与BP分类器结合的方法进行对比,精度大约提高了4%,说明本文方法具有良好的故障状态识别结果,并且本文方法简化了特征提取方法的设计,不需要去设计非常巧妙的特征提取器。

综合图2、3以及表2中结果可以得出,DBN模型具有直接从原始时域信号自动提取故障特征和识别的能力,不但能够取得比较好的识别精度,而且简化了传统故障诊断方法中的特征提取过程。

5 轴承数据集验证

轴承作为重大机械设备的关键部分,其工作状态正常与否直接关系到整个设备的性能<sup>[18]</sup>,因此对重大机械设备中的轴承进行故障诊断具有现实意义。通过轴承故障诊断实验进一步验证了利用 DBN 模型从原始信号中进行故障特征提取及诊断的能力。

5.1 数据集描述和故障类型定义

本部分实验使用的数据集为美国凯斯西储大学电子工程实验室采集的轴承数据集<sup>[19]</sup>。此数据集是以 12 kHz 的采样频率,在 4 种不同的负荷(0~3 hp)下采集得到。此轴承实验系统模拟了轴承的正常状态、外圈故障,内圈故障和滚珠故障 4 种故障类型,且每种故障类型都有 3 种故障深度。以 0~2 hp 3 种负荷下的实验数据,分别构造 3 种数据集 A、B 和 C,每个数据集包含 10 种故障类别。使用包含 2 048 个点的窗口对采集的原始振动信号进行划分,则每种故障类别可以得到 50 个样本。考虑到实际情况中,同一种故障类别可能对应多种负荷,综合数据集 A~C,得到数据集 D。这 4 种数据集 A~D 统计如表 3 所示,其中 Normal 代表轴承的正常状态,RF、IF、OF 分别代表滚珠、轴承内圈和外圈故障,RF1-3 代表不同的故障深度。

表 3 轴承故障数据集描述

Table 3 Description of bearing fault datasets

故障类别	故障深度/mm	数据集 A/B/C	数据集 D	故障类别
正常	0	50	150	1
RF1	0.18	50	150	2
RF2	0.36	50	150	3
RF3	0.54	50	150	4
IF1	0.18	50	150	5
IF2	0.36	50	150	6
IF3	0.54	50	150	7
OF1	0.18	50	150	8
OF2	0.36	50	150	9
OF3	0.54	50	150	10

5.2 实验结果

首先对原始数据进行线性归一化变换,使其范围限制在[0, 1]内,后面所提原始数据皆是归一化后的数据。DBN 模型采用经典的 5 层模型,节点数为 2 048-1 200-600-300-10。以正态随机分布初始化 DBN 模型的权重,DBN 模型的阈值初始化为 0。RBM 的最大迭代次数为 100,学习率为 0.1,动量参数为 0.9。随机选取每个故障

类别样本的 60% 作为训练,剩下的作为测试。4 种数据集 A~D 中,数据集 A~C 具有同一性质,即都是在单一负荷下采集得到,因此数据集 A~C 放在一起进行结果分析。由于篇幅限制,本文仅仅给出了利用 DBN 模型对数据集 A 进行故障特征提取的可视化结果,如图 4~7 所示。




图 4 数据集 A 的原始特征可视化图  
Fig. 4 Visualization of the raw features in dataset A




图 5 数据集 A 的第一隐层特征可视化  
Fig. 5 Features visualization of the first hidden layer in dataset A




图 6 数据集 A 的第 2 隐层特征可视化图  
Fig. 6 Features visualization of the second hidden layer in dataset A






图 7 数据集 A 的第 3 隐层特征可视化图

Fig.7 Features visualization of the third hidden layer in dataset A

由图 4~7 可以看出,DBN 能够对单一负荷下不同故障深度和故障类型的数据集进行较好的特征提取。考虑到实际情况中,同一种故障有可能在不同的负荷下产生,在这种考虑下构造了数据集 D,图 8 给出了数据集 D 的原始特征可视化结果,图 9 给出了利用 DBN 模型对数据集 D 进行故障特征提取的可视化结果。




图 8 数据集 D 的原始特征可视化

Fig.8 Visualization of the raw features in dataset D




图 9 数据集 D 的第 3 隐层特征可视化图

Fig.9 Features visualization of the third hidden layer in dataset D

万方数据

从图 8 可以看出,仅有 2 种故障被区分开,其余的 8 种故障紧紧聚集在一起。从图 9 可以看出,当经过 DBN 模型逐层提取特征之后,大部分故障可以直接分开,并且 10 种故障类别处于一种向外发散的状态,虽然会有细微的重叠,但整体能够被区分开。综合图 8 和 9 中结果,明显可以看到图 9 中有更少的重叠空间,并且整体是一个发散状态,更利于分类器进行区分。因此 DBN 模型不仅可以在单一工况下进行故障特征提取,而且能够在多种工况下进行故障特征提取。

为了评估 DBN 模型的故障识别能力,在进行故障特征提取的基础上,对故障进行进一步的识别分类。将本文提出的方法与传统的故障诊断方法进行比较,比较结果如表 4 所示。表 4 中 DBN 的分类准确率是 10 次平均的结果,即对每个数据集重复运行 10 次,取 10 次故障分类准确率的均值。

表 4 轴承数据集的诊断结果

方法	数据集 A 数据集 B 数据集 C 数据集 D			
	(%)			
多重分形 + SVM <sup>[20]</sup>	89.1	—	—	—
SS-DPSOM <sup>[21]</sup>	—	—	—	95.8
Time + MLP <sup>[22]</sup>	95.7	99.6	99.4	—
PSO-WKLFDA <sup>[6]</sup>	97.2	—	—	—
OAO- PSO-WKLFDA <sup>[6]</sup>	98.8	—	—	—
频域 + DBN <sup>[14]</sup>	99.9	99.6	99.7	99.6
时域信号 + DBN	100	100	100	98.8

在文献[20]中,使用多重分形的方法进行故障特征提取,然后输入到 SVM 分类器中进行故障识别,此方法给出了负载 0 条件下的 10 种故障种类识别率,为 89.1%,利用 DBN 方法从原始数据集 A 中进行故障诊断,精度达到了 100%,提高了 10.9%。文献[21]提出了半监督距离保持自组织方法,并使用此方法提取出 19 个频域和时域特征,该方法对不同负载下的 3 类球故障进行分类,获得了 95.8% 的准确率,而在本文方法中,数据集 D 是对不同负荷下的 10 种故障进行分类,在数据集更复杂的情况下,仍然取得了 98.8% 的准确率。在文献[22]中,使用数学统计方法提取时域特征,并使用多层感知机对 3 类数据集的 6 种故障进行分类,分别获得了 95.7%、99.6% 和 99.4% 的故障识别率,本文方法在增加故障种类的情况下,取得了 100%、100% 和 100% 的故障识别率,优于文献[22]中方法。文献[6]中的 OAO-PSO-WKLFDA 方法是目前最新的方法,对负载 0 条件下的 10 种故障种类进行识别,取得了 98.8% 的故障识别率,利用本文提出的方法对相似的数据集 A 进行故障诊

断,取得了 100% 准确率,要优于目前最新的方法。为了更准确地验证 DBN 方法从原始时域信号进行故障诊断的能力,与文献[14]中利用 DBN 方法从频域信号中进行故障诊断的识别率进行对比,两者的故障识别率相当,不过本文方法摆脱了对信号处理技术的依赖,对监测信号的周期性也没有严格要求,真正做到了从原始时域信号进行故障特征提取和诊断。综合表 4 中结果,说明利用 DBN 模型直接从原始数据中进行故障特征提取及诊断具有比较大的优势。对于更接近实际情况的数据集 D, DBN 方法也取得了较高的故障诊断精度,充分说明利用 DBN 模型从原始信号中进行故障诊断的方法可以适应复杂工况,准确识别故障位置和故障程度。

## 6 结 论

本文提出了一种面向原始时域信号的故障特征提取和诊断方法,该方法基于深度学习框架,将故障特征提取和分类集成在一个模型中。在仿真数据集和轴承数据集上验证了该方法的有效性,结果表明:1) DBN 模型能够从原始时域信号中逐层提取故障特征,并获得较高的诊断准确率;2) 与传统的特征提取方法相比,本文方法在不依赖信号处理技术和专家经验的情况下,仍然取得高于传统方法的分类精度;3) 本文方法不受限于信号的周期性,增强了故障诊断方法的通用性和实用性。由于时间关系,本文所用方法只考虑了单一信号的情况,而实际情况中,对于每一个诊断系统都会有多个传感器同时采集数据,如何利用深度学习方法从多源异构传感器数据中有效的对复杂系统进行故障诊断是今后需要进一步研究的方向。

## 参考文献

- [1] 彭宇,刘大同. 数据驱动故障预测和健康管理综述[J]. 仪器仪表学报, 2014, 35(3): 481-495.  
PENG Y, LIU D T. Data-driven prognostics and health management: A review of recent advances[J]. Chinese Journal of Scientific Instrument, 2014, 35(3): 481-495.
- [2] 彭宇,刘大同,彭喜元. 故障预测与健康管理技术综述[J]. 电子测量与仪器学报, 2010, 24(1): 1-9.  
PENG Y, LIU D T, PENG X Y. A review: Prognostics and health management [J]. Journal of Electronic Measurement and Instrument. 2010, 24(1): 1-9.
- [3] 李丽敏. 统计聚类 and 粒子滤波在故障诊断中的应用研究[D]. 西安:西北工业大学, 2014: 3-4.  
LI L M. Application research for fault diagnosis based on statistical clustering and particle filter [D]. Xi'an: Northwestern Polytechnical University, 2014: 3-4.
- [4] 闫鹏程, 孙平刚, 毛向东, 等. 基于 EMD 与 SVD 的齿

轮箱分形诊断方法研究[J]. 电子测量与仪器学报, 2012, 26(5): 404-412.

YAN P CH, SUN H G, MAO X D, et al. Research of fractal diagnosis method for gearbox based on EMD and SVD [J]. Journal of Electronic Measurement and Instrument. 2012, 26(5): 404-412.

- [5] WANG H, CHEN J, DONG G. Feature extraction of rolling bearing's early weak fault based on EEMD and tunable Q-factor wavelet transform [J]. Mechanical Systems & Signal Processing, 2014, 48(1-2): 103 - 119.
- [6] VAN M, KANG H. Bearing defect classification based on individual wavelet local fisher discriminant analysis with particle swarm optimization [J]. IEEE Transactions on Industrial Informatics, 2016, 12(1): 124-135.
- [7] 雷亚国, 贾峰, 周昕, 等. 基于深度学习理论的机械装备大数据健康监测方法[J]. 机械工程学报, 2015, 51(21): 49-56.  
LEI Y G, JIA F, ZHOU X, et al. A deep learning-based method for machinery health monitoring with big data [J]. Journal of Mechanical Engineering, 2015, 51(21): 49-56.
- [8] LECUN Y, BENGIO Y, HINTON G E. Deep learning [J]. Nature, 2015, 521(14539): 436-444.
- [9] HINTON G E, SALAKHUTDINOV R R. Reducing the dimensionality of data with neural networks [J]. Science, 2006, 313(5786): 504-507.
- [10] TAMILSELVAN P, WANG P. Failure diagnosis using deep belief learning based health state classification [J]. Reliability Engineering & Systems Safety, 2013, 115(7): 124-135.
- [11] TRAN V T, ALTHOBIANI F, Ball A. An approach to fault diagnosis of reciprocating compressor valves using Teager-Kaiser energy operator and deep belief networks [J]. Expert Systems with Applications, 2014, 41(9): 4113-4122.
- [12] SHAO H, JIANG H, ZHANG X, et al. Rolling bearing fault diagnosis using an optimization deep belief network [J]. Measurement Science & Technology, 2015, 26(11): 115002-115018.
- [13] LI C, SANCHEZ R V, ZURITA G, et al. Multimodal deep support vector classification with homologous features and its application to gearbox fault diagnosis [J]. Neurocomputing, 2015, 168(C): 119-127.
- [14] JIA F, LEI Y G, LIN J, et al. Deep neural networks: A promising tool for fault characteristic mining and intelligent diagnosis of rotating machinery with massive data [J]. Mechanical Systems & Signal Processing,

- 2015,72:303-315.
- [15] BENGIO Y. Learning deep architectures for AI [J]. Foundations & Trends in Machine Learning, 2009, 2(1):121-127.
- [16] HINTON G E. A Practical Guide to Training Restricted Boltzmann Machines [M]. Neural Networks: Tricks of the Trade, 2012:599-619.
- [17] 李锋. 基于流形学习的风电机组传动系统故障诊断方法研究[D]. 重庆:重庆大学, 2011:62-64.
- Li F. Research on methods of fault diagnosis for wind turbine transmission system based on manifold learning [D]. Chongqing: Chongqing University, 2011:62-64.
- [18] 张立国, 李盼, 李梅梅, 等. 基于 ITD 模糊熵和 GG 聚类的滚动轴承故障诊断[J]. 仪器仪表学报, 2014, 35(11):2624-2632.
- ZHANG L G, LI P, LI M M, et al. Fault diagnosis of rolling bearing based on ITD fuzzy entropy and GG clustering [J]. Chinese Journal of Scientific Instrument. 2014, 35(11): 2624-2632.
- [19] LOPARO K A. Bearing data center, case western reserve university [EB/OL]. Available: <http://www.eecs.case.edu/laboratory/bearing>, 2013.
- [20] DU W, TAO J, LI Y, et al. Wavelet leaders multifractal features based fault diagnosis of rotating mechanism [J]. Mechanical Systems & Signal Processing, 2014, 43(1): 57-75.
- [21] LI W, ZHANG S, HE G. Semisupervised distance-preserving self-organizing map for machine-defect

detection and classification [J]. IEEE Transactions on Instrumentation & Measurement, 2013, 62(5):869-879.

- [22] ALMEIDA L F D, BIZARRIA J W, BIZARRIA F C, et al. Condition-based monitoring system for rolling element bearing using a generic multi-layer perceptron [J]. Journal of Vibration & Control, 2015, 21 (16): 3456-3464.

## 作者简介



**赵光权**, 2007 年于哈尔滨工业大学获得博士学位, 现为哈尔滨工业大学副教授、硕士生导师, 主要研究方向为深度学习、智能测试信息处理。

E-mail: hit53zhao@hit.edu.cn

**Zhao Guangquan** received his Ph. D. degree in 2007 from Harbin Institute of Technology (HIT), now he is an associate professor and master student supervisor in HIT. His main research interests include deep learning and intelligent test information processing.



**葛强强**, 2014 年于哈尔滨理工大学获得学士学位, 现为哈尔滨工业大学硕士研究生, 主要研究方向为深度学习、智能故障诊断。

E-mail: gqq910927@126.com

**Ge Qiangqiang** received his B. Sc. degree in 2014 from Harbin University of Science And Technology. Now He is a master student in HIT. His main research interests include deep learning and intelligent fault diagnosis.