

基于 ITD 模糊熵和 GG 聚类的滚动轴承故障诊断*

张立国¹, 李 盼¹, 李梅梅², 张淑清¹, 张志福¹

(1. 燕山大学电气工程学院 河北省测试计量技术及仪器重点实验室 秦皇岛 066004;

2. 东北大学秦皇岛分校计算机与通信工程学院 秦皇岛 066004)

摘 要: 提出了一种本征时间尺度分解模糊熵和 GG 模糊聚类的滚动轴承故障诊断方法。首先, 将滚动轴承的振动信号进行 ITD 分解, 得到若干个固有旋转分量和一个趋势项。然后, 将 PR 分量分别与原始信号进行相关性分析, 筛选出前 3 个含主要特征信息的 PR 分量, 并将筛选的 PR 分量的模糊熵作为特征向量。最后, 将特征向量输入到 GG 分类器中进行聚类识别。通过模糊熵、样本熵和近似熵对比, 实验结果表明模糊熵能更好的表征故障信号的特征信息; 通过 GG 聚类、GK 聚类和 FCM 聚类对比, 实验结果表明 GG 聚类效果明显优于 FCM、GK 的聚类效果。因此, 实验证明了基于 ITD 模糊熵和 GG 聚类的滚动轴承故障诊断方法的有效性和优越性。

关键词: 本征时间尺度分解; 模糊熵; GG 模糊聚类; 故障诊断

中图分类号: TH17 **文献标识码:** A **国家标准学科分类代码:** 510.40

Fault diagnosis of rolling bearing based on ITD fuzzy entropy and GG clustering

Zhang Ligu¹, Li Pan¹, Li Meimei², Zhang Shuqing¹, Zhang Zhifu¹

(1. Institute of Electrical Engineering, Yanshan University, Key Laboratory of Measurement Technology and Instrumentation of Hebei Province, Qinhuangdao 066004, China; 2. Institute of Computer and Communication Engineering, Northeastern University at Qinhuangdao, Qinhuangdao 066004, China)

Abstract: A new method for rolling bearing fault diagnosis based on the intrinsic time-scale decomposition (ITD) fuzzy entropy and Gath-Geva (GG) clustering algorithm is introduced. Firstly, rolling bearing vibration signal is decomposed with ITD to obtain several proper rotation (PR) components and a tendency item. Secondly, the first three PR components, which content the primary feature information, were chosen by the criteria of correlation with the original signal, and the fuzzy entropies of each PR component are composed eigenvectors. Finally, the constructed eigenvectors are put into GG classifier to recognize different fault types. In the experiment, the fuzzy entropy compares with sample entropy and approximate entropy, the comparison experimental results show that the fuzzy entropy can characterize the feature information of the fault signal better; the GG clustering compares with Gustafson-Kessel (GK) clustering and fuzzy center means (FCM) clustering. The comparison experimental results show that the result of GG clustering is superior to FCM and GK's. So, experimental results show that the rolling bearing fault diagnosis method based on ITD fuzzy entropy and GG clustering is effective and superior.

Keywords: ITD; fuzzy entropy; Gath-Geva fuzzy clustering; fault diagnosis

1 引言

滚动轴承是机械设备的重要组成部分, 其运行状态正常与否直接关系到整个机组的性能^[1], 因此对滚动轴承的振动信号进行故障特征提取和模式识别具有十分重要的意义。

对信号进行预处理以便消除原始信号中的噪声和降低特征信息之间的混叠现象至关重要, 常用的预处理方法有: 经验模态分解(empirical mode decomposition, EMD)、集合经验模态分解(ensemble empirical mode decomposition, EEMD)、局域均值分解(local mean decomposition, LMD)等信号分解方法。蔡剑华等^[2]提出了 EMD-Wigner 高阶矩谱的齿轮故障诊断方法, 王玉静等^[3]提出了基于优化 EEMD 的滚动轴承故障位置及性能退化程度诊断方法。王建国等^[4]提出基于自相关分析和 LMD 的滚动轴承振动信号故障特征提取方法。本征时间尺度分解(intrinsic time-scale decomposition, ITD)能够准确的提取非平稳信号的动态特征, 迭代次数少, 边缘效应小, 适合实时在线处理数据。

熵值是一种表征信号复杂程度的指标, 能够有效的降低特征向量的维数, 充分表征信号的特征信息。能量熵、信息熵、近似熵(ApEn)、样本熵(SampEn)等常作为信号的特征向量。姚亚夫等^[5]提出瞬时能量熵特征提取方法应用于滚动轴承故障诊断中, 文莹等^[6]提出基于信息熵属性约简的航空发动机故障诊断方法。黄娟等^[7]提出基于小波包近似熵的线路故障性质辨识方法。张文斌等^[8]提出一种基于谐波窗分解样本熵与灰色关联度相结合的转子故障识别方法。模糊熵(FuzzyEn)对样本熵、近似熵进行了改进, 在数据独立性和相对一致性方面更加突出。

聚类分析是模式识别方法的重要研究领域之一, 谱聚类、K-means 聚类、FCM (fuzzy center means) 聚类、GK(Gustafaon-Kessel)聚类等聚类算法广泛应用在聚类识别方面。张焱^[9]等提出基于谱聚类初始化非负矩阵分解的机械故障诊断方法, 刘慧婷^[10]等提出基于 EMD 与 K-means 算法的时间序列聚类方法, M.Zarinbal^[11]等提出相对熵 FCM 聚类方法, Lisa Serir^[12]等提出证据进化 GK 聚类的在线聚类方法。GG(Gath-Geva)聚类算法是对 FCM 聚类算法和 GK 聚类算法的改进。通过引入基于模糊最大似然估计的距离范数, 可以反映不同形状和方向的数据类。

本文提出将 ITD 模糊熵和 GG 聚类相结合的方法运用到滚动轴承的故障诊断中, 通过模糊熵和近似熵、样本熵的对比, 以及 GG 聚类与 FCM 聚类、GK 聚类对比, 说明了本方法的优越性。

2 本征时间尺度分解 ITD

设待分解信号 X_t 为一实值离散信号, 定义 ξ 为 X_t 的基线提取因子, 定义 $H_t = X_t - \xi X_t$ 为合理旋转分量, 其中 ξX_t 为信号的均值曲线, 简记为 L_t , 则 ITD 算法步骤为^[13]:

1) 提取 X_t 的极值点 X_k 和对应的时间点 $\tau_k(k=1, 2, \dots, N)$, 定义 $\tau_0=0$, 并定义:

$$L_{k+1} = \alpha[X_k + (\frac{\tau_{k+1} - \tau_k}{\tau_{k+2} - \tau_k})(X_{k+2} - X_k)] + (1-\alpha)X_{k+1} \quad (1)$$

($k=1, 2, \dots, N-2$)

式中: $\alpha \in [0, 1]$, 一般取 $\alpha = 0.5$ 。

2) 定义信号 X_t 的分段线性基线提取因子:

$$L_t = \xi X_t = L_k + (\frac{L_{k+1} - L_k}{X_{k+1} - X_k})(X_t - X_k) \quad (2)$$

3) 将基线信号 L_t 作为原始信号重复步骤(1)~(2), 则原始信号被分解为:

$$X_t = \xi X_t + HX_t = (H \sum_{k=0}^{p-1} \xi^k + \xi^p) X_t \quad (3)$$

式中: $H \xi^k X_t$ 是第 $k+1$ 个固有旋转 (proper rotation, PR) 分量, $\xi^p X_t$ 为单调趋势信号。

3 模糊熵及参数选择

模糊熵一般定义如下^[14]:

1) 对 N 点序列 $\{u(i): 1 \leq i \leq N\}$ 构造 m 维向量:

$$X_i^m = \{u(i), u(i+1), \dots, u(i+m-1)\} - u_0(i) \quad (4)$$

($i=1, 2, \dots, N-m+1$)

2) 定义向量 X_i^m 和 X_j^m 的距离 d_{ij}^m 为两者对应元素之差的最大值, 即:

$$d_{ij}^m = d[X_i^m, X_j^m] = \max_{k \in (0, m-1)} (|u(i+k) - u_0(i)| - |u(j+k) - u_0(j)|) \quad (5)$$

$$i, j = 1, 2, \dots, N-m; i \neq j$$

3) 定义函数:

$$\phi^m(n, r) = \frac{1}{N-m} \sum_{i=1}^{N-m} (\frac{1}{N-m-1} \sum_{j=1, j \neq i}^{N-m} D_{ij}^m) \quad (6)$$

式中: 隶属度函数 $D_{ij}^m = e^{-(d_{ij}^m/r)^n}$, r 为相似容限。

4) 定义模糊熵为:

$$\text{FuzzyEn}(m, n, r) = \lim_{N \rightarrow \infty} (\ln \phi^m(n, r) - \ln \phi^{m+1}(n, r)) \quad (7)$$

当 N 为有限值时, 式(7)表示为:

$$\text{FuzzyEn}(m, n, r, N) = \ln \phi^m(n, r) - \ln \phi^{m+1}(n, r) \quad (8)$$

以滚动体故障信号为例, 选取30组样本, 分析模糊熵、样本熵和近似熵随参数变化的变化情况。3种熵值的参数初定为 $m=2, r=0.2, n=2$ 。计算各熵值随 N 从100到1000变化的平均值, 结果如图1所示。




图1 3种熵值随 N 变化情况

Fig. 1 The change of the three kinds of entropy with N

从图1中可以看到, 模糊熵和样本熵随着数据长度 N 的变化相对稳定, 而近似熵随着数据长度的增加而增加。因此, 模糊熵和样本熵更独立于数据长度。

同样, 设置 $m=2, n=2, N=1024$, 分析3种熵值随 r 从0.05到1变化的标准差, 结果如图2所示。样本熵的标准差在 $0.05 < r < 0.2$ 变化时急剧减小, 当 $r > 0.2$ 时逐渐平稳; 近似熵的标准差在 $0.05 < r < 0.4$ 之间上下波动, $r > 0.4$ 时, 逐渐平稳。模糊熵的标准差随着 r 的变化基本维持在0.027附近。因此, 模糊熵的稳定性和相对一致性更好。




图2 3种熵值的SD随 r 变化情况

Fig. 2 The change of the SD with r

因此, 参数 N 和 r 对于模糊熵相对稳定, 当 $N=1024$ 时, $r=0.2$ 时, 模糊熵随 m, n 的变化情况如图3所示。当 $n > 1$ 时, 模糊熵随 n 变化趋于稳定, 当参数 $m=2$ 时, 模糊熵最大, 能表示更丰富的特征信息, 当 $m > 3$ 时, 模糊熵趋于稳定。




图3 模糊熵随 m, n 变化情况

Fig. 3 The change of FuzzyEn with m and n

综上所述, 当参数 $N > 1000$ 时, 3种熵均趋于稳定, 为能充分提取特征信息取 $N=2048$; 参数 r 为比较窗口的边界宽度, 当 $r > 0.2$ 时, 3种熵值的标准差比较稳定, r 太大会丢失特征信息, 因此取 $r=0.2$; 参数 n 为相似容限边界的梯度, n 太大会导致细节信息丧失, 本文取 $n=2$; 参数 m 为嵌入维数, 一般取值2或3, 为提取更丰富的特征信息取 $m=2$ 。

4 GG 模糊聚类算法

GG 聚类算法如下^[15]:

设聚类样本集合 $X = \{x_1, x_2, \dots, x_N\}$, 其中的任意一个元素 $x_k (1 \leq k \leq N)$ 均有 d 个特性指标, 即 $x_k = \{x_{k1}, x_{k2}, \dots, x_{kd}\}$, 现把聚类样本集合 X 分为 c 类 ($2 \leq c \leq N$), 设其中每个分类的聚类中心向量为 $V = (v_1, v_2, \dots, v_c)$; 设隶属度矩阵 $U = [\mu_{ik}]_{c \times N}$, 其中元素 $\mu_{ik} \in [0, 1]$ 表示第 k 个样本对第 i 类的隶属度 ($1 \leq i \leq c$)。GG 聚类准则是通过迭代调整 (U, V) 使如下目标函数 J_m 取得最小值:

$$J_m(U, V) = \sum_{i=1}^c \sum_{k=1}^N (\mu_{ik})^m D_{ik}^2 \quad (9)$$

式中: $m > 1$ 为加权指数, m 越大各聚类之间的重叠越多, 通常取2即可。具体步骤如下:

1) 计算聚类中心

$$v_i^{(l)} = \frac{\sum_{k=1}^N (\mu_{ik}^{(l-1)})^m x_k}{\sum_{k=1}^N (\mu_{ik}^{(l-1)})^m}, 1 \leq i \leq c \quad (10)$$

$$u(x_k, v_i) = \exp\left(\frac{1}{2}(x_k - v_i^{(l)})^T A_i^{-1}(x_k - v_i^{(l)})\right) \quad (11)$$

式中: A_i 为第 i 个聚类的协方差矩阵。

2) 更新分类矩阵

$$\mu_{ik}^{(l)} = \frac{1}{\sum_{j=1}^c \left(\frac{D_{jk}(x_k, v_j)}{D_{ik}(x_k, v_i)}\right)^{\frac{2}{m-1}}}, 1 \leq i \leq c, 1 \leq k \leq N \quad (12)$$

若满足条件 $\|U^{(l)} - U^{(l-1)}\| < \varepsilon$ 则终止, 否则继续令 $l=l+1$, 重复上述步骤, 直至满足条件。

5 实验分析

实验数据源于美国大学 Case Western Reserve University 电气工程实验室的滚动轴承实验数据。其轴承为 SKF 轴承, 电机功率 2HP, 轴承局部故障是通过电火花技术人为加工的单点故障。

为了说明 ITD 模糊熵和 GG 聚类的优越性, 采用聚类有效性指标: 划分系数(partition coefficient, PC)、划分熵(classification entropy, CE), XB (Xie-Beni) 指标进行对比实验。

5.1 不同类型故障分析

实验数据故障类型分为轴承正常、滚动体故障、内圈故障、外圈故障四种类型。故障直径为 0.177 8 mm, 数据采样频率为 12 kHz, 每种类型取 30 组数据样本, 样本长度 $N=2\ 048$, 以外圈故障信号 $x(t)$ 为例, 对信号进行 ITD 分解, 得到 8 个 PR 分量和余项 Res, 如图 4 所示。

故障信号经 ITD 分解后的 PR 分量按照有高频到低频排列, 通常前几个 PR 分量包含原始信号的主要特征信息。通过相关性分析, 第一个 PR 分量是与原始信号的皮尔逊相关系数为 0.991 9, 对前 3 个 PR 分量重构后与原始信号的相关系数为 0.999 4。因此, 选取前 3 个 PR 分量足以表征原始信号的特征信息。

分别对 4 种数据进行 ITD 分解, 并取前 3 个分量, 构成 4 组 PR 分量数据, 每组维数为 $2048 \times 3 \times 30$ 。通过对 4 组 PR 分量数据求取模糊熵, 得到 4 组 3×30 的模糊熵, 其均值如表 1 所示:




图 4 外圈故障信号的 PR 分量

Fig. 4 The PR components of the outer ring fault signal

表 1 前 3 个 PR 分量的模糊熵

Table 1 The fuzzy entropy of first three PR components

信号类型	模糊熵		
	PR1	PR2	PR3
正常信号	1.537 9	0.933 2	0.238 3
滚动体故障	2.380 8	1.365 7	0.733 8
内圈故障	1.945 1	1.270 4	0.804 5
外圈故障	1.475 1	1.225 2	0.611 2

从表 1 中可以发现, PR1~PR3 的模糊熵依次减小, 表明他们的复杂程度依次降低, 并且不同信号的模糊熵不同, 说明不同的故障信号的复杂度不同。因此, 模糊熵可以作为四种类型信号的特征信息, 为聚类分析提供依据。

根据 4 种故障类型数据, 聚类中心个数初定为 $c=4$, 加权指数 $m=2$, 迭代终止容差 $c=0.0001$ 。对上述 4 组 3×30 的模糊熵数据进行 GG 聚类分析, 结果如图 5 和图 6 所示, V1~V4 为聚类中心, 4 种类型的数据分别聚集在聚类中心附近, 并且聚集紧密, 各类之间没有出现混叠现象, 并且间距较大。




图 5 模糊熵的 GG 聚类三维空间图

Fig. 5 The spatial graph of GG clustering for FuzzyEn

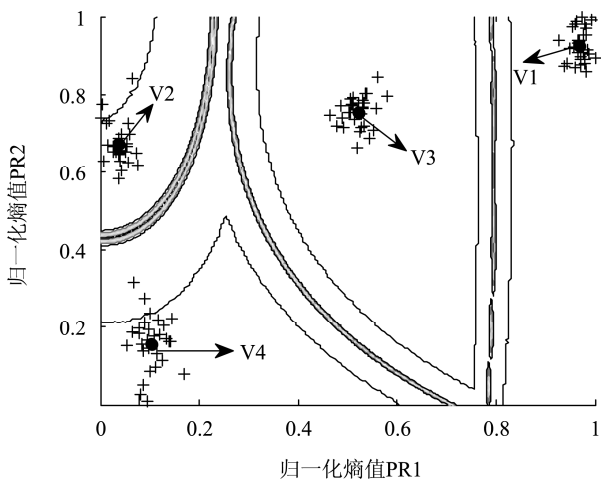


图 6 模糊熵的 GG 聚类等高线图

Fig. 6 The GG clustering contour for FuzzyEn

具体的各类型数据的聚类中心和隶属度如表 2、表 3 所示。如表 2 所示,4 种信号类型的聚类中心依次为 V1~V4。表 3 为各组样本集合隶属度的平均值,第 1 组样本对于 V4 的隶属度为 0.9745,接近 1,且远大于其他 3 组,因此第 1 组样本属于 V4 类;同理,第 2 组隶属于 V1 类,第 3 组隶属于 V3,第 4 组隶属于 V2。因此,本文方法在滚动轴承的故障诊断中具有良好的效果。

为进一步验证模糊熵相对于样本熵、近似熵的优越性,对上述 4 组信号分别求取样本熵、近似熵,然后进行 GG 聚类分析,结果如表 4 和图 7、8 所示:

由图 5 和图 7、8 对比可以得出: 1) 不同的熵值的提取方法不同,4 种类型数据的聚类中心不一样。

表 2 4 种类型信号的聚类中心

Table 2 The clustering centers of the four types signals

信号类型	聚类中心		
	x	y	z
滚动体故障(V1)	0.969 0	0.925 7	0.813 2
外圈故障(V2)	0.037 9	0.675 2	0.631 2
内圈故障(V3)	0.521 1	0.755 7	0.918 3
正常信号(V4)	0.102 4	0.154 2	0.077 1

表 3 4 种类型信号的隶属度

Table 3 The membership of the four types signals

样本组号	隶属度			
	V1	V2	V3	V4
1	0.001 4	0.018 3	0.005 8	0.974 5
2	0.990 1	0.000 7	0.008 0	0.001 2
3	0.004 4	0.002 9	0.990 0	0.002 7
4	0.001 3	0.982 0	0.009 1	0.007 6

表 4 3 种熵值的聚类评价指标

Table 4 The clustering evaluation index for the entropy

熵	聚类评价指标		
	PC	CE	XB
样本熵	0.934 1	0.164 0	6.943 5
近似熵	0.952 2	0.131 0	2.934 5
模糊熵	0.995 6	0.002 2	2.068 0




图 7 样本熵的 GG 聚类三维空间图

Fig. 7 The spatial graph of GG clustering for SampEn




图 8 近似熵的 GG 聚类三维空间图

Fig. 8 The spatial graph of GG clustering for ApEn

2)模糊熵的 GG 聚类结果的类内紧致性好于样本熵和近似熵。根据表 4 可知, 模糊熵的聚类分析指标 PC 为 0.995 6, 均大于样本熵和近似熵, 更接近于 1; 而指标 CE 为 0.002 2 均小于样本熵和近似熵, 更接近于 0; 模糊熵的指标 XB 为 2.068 0, 均小于样本熵和近似熵。由聚类有效性可知, PC 越接近 1, CE 越接近于 0, XB 值越小, 聚类效果越好。因此, 模糊熵的特征提取方法相对于样本熵和近似熵更好。

为验证 GG 聚类方法相对于 FCM 和 GK 的优越性, 对上述模糊熵数据进行 FCM 和 GK 聚类分析, 结果如表 5 和图 9、图 10 所示。

表 5 不同故障信号 FCM、GK、GG 的聚类指标

Table 5 The FCM, GK and GG clustering index for signals

聚类方式	聚类评价指标		
	PC	CE	XB
FCM	0.957 2	0.113 0	7.235 3
GK	0.960 0	0.100 8	6.511 0
GG	0.995 6	0.002 2	2.068 0




图 9 模糊熵的 FCM 聚类等高线图

Fig. 9 The FCM clustering contour for FuzzyEn




图 10 模糊熵的 GK 聚类等高线图

Fig. 10 The GK clustering contour for FuzzyEn

从图 6 和图 9 可以看出, GG 聚类和 FCM 聚类的聚类中心相似, 这说明不同聚类方法对聚类中心的影响较小; 同时, GG 聚类和 FCM、GK 聚类的类内紧致性和空间分布相似。但从等高线形状可以看出, FCM 聚类算法的等高线近似为球形, 这表明 FCM 只能反映超球形数据结构的标准距离规范; 而 GK 聚类算法的等高线图相对于 FCM 有所改善, 但仍为近似球形; GG 聚类算法的等高线图没有固定形状, 表明 GG 可以反映数据在任何方向或任意子空间的分散程度。根据表 5 中的聚类指标可以看到, GG 聚类的 PC 值大于 FCM、GK 聚类, CE、XB 的值均小于 FCM、GK 聚类。经上述分析, GG 聚类算法优于 FCM、GK 聚类算法。

应用最大贴近度原则来进行故障识别, 某待测样本经 ITD 和模糊熵处理后得到特征向量 $A=[1.450\ 4\ 1.253\ 6\ 0.655\ 8]$, 根据表 2 可知不同种类的聚类中心, 则贴近度: $N(A_x, V_1)=0.530\ 1$, $N(A_x, V_2)=0.902\ 7$, $N(A_x, V_3)=0.654\ 0$, $N(A_x, V_4)=0.159\ 8$ 。因此, 根据择近原则可知 A 属于外圈故障, 与实际相符。

5.2 不同损伤程度的故障分析

为进一步验证本文方法的有效性, 对不同损伤程度的故障信号进行分析。选取滚动体的正常信号、轻微故障信号、中度故障信号、严重故障信号 4 种类型信号进行分析, 其损伤直径依次为 0.177 8 mm、0.5334 mm、0.711 2 mm, 损伤深度均为 0.279 4 mm。

同样对上述 4 种数据类型进行 ITD 分解, 然后进行模糊熵特征信息提取, 得到 120×3 维的模糊熵作为特征向量, 并进行 GG 聚类分析, 结果如图 11 所示。




图 11 不同程度故障信号的 GG 聚类等高线图
Fig. 11 The GG clustering contour for different fault signals

根据图 11 可知对 4 种不同程度的信号, 实现了很好的聚类识别。这说明, 本文方法不仅对不同种类的故障信号有效, 对不同程度故障信号同样有效。

分别对上述信号进行 FCM、GK 聚类分析, 结果如图 12、13 所示, FCM 聚类的等高线图仍然是球形, 而 GK 聚类仍为近似球形。聚类指标如表 6 所示, GG




图 12 不同程度故障信号的 FCM 聚类等高线图
Fig. 12 The FCM clustering contour for different fault signals




图 13 不同程度故障信号的 GK 聚类等高线图
Fig. 13 The GK clustering contour for different fault signals

表 6 不同程度故障信号 FCM、GK、GG 的聚类指标
Table 6 The FCM, GK and GG clustering index for different degree fault signals

聚类方式	聚类指标		
	PC	CE	XB
FCM	0.929 1	0.165 7	8.001 1
GK	0.936 6	0.158 2	5.150 1
GG	0.997 0	0.001 5	1.846 2

聚类指标 PC、CE、XB 均优于 FCM 和 GK 的聚类指标。因此, GG 聚类算法针对不同损伤程度的故障信号均优于 FCM、GK 聚类算法。

5.3 工程数据分析

为验证本文方法的工程实用性, 对 1580SP 轧机的减速机的两组监测数据进行分析, 两组数据为不同时间采集, 第 1 组为正常数据, 第 2 组为疑似故障数据。将两组数据分别截取 29 段样本, 每段数据长度为 2048 个点, 采样频率为 30 kHz。对两组数据进行模糊熵提取, 其 GG 聚类分析的结果如图 14 所示。

根据图 14 可知, 两组数据聚类中心 V1、V2 相聚较远, 第 1 组数据的类内紧致性较好, 第 2 组有个别点远离聚类中心 V2, 但整体上对两组数据实现了聚类识别, 且效果明显。由于工程现场复杂, 故障样本不完善, 疑似故障数据的故障类型有待验证。




图 14 工程数据的 GG 聚类等高线图

Fig. 14 The GG clustering contour for engineering data

两组数据的 FCM、GK、GG3 种方法聚类指标如表 7 所示, GG 聚类方法依然优于 FCM 和 GK 方法。因此, 本方法对工程数据的分类仍有较好的效果。

表 7 工程数据的 FCM、GK、GG 聚类指标
Table 7 The FCM, GK and GG clustering index for engineering data

聚类方式	聚类指标		
	PC	CE	XB
FCM	0.986 5	0.035 6	5.412 6
GK	0.988 9	0.030 4	4.143 0
GG	0.993 9	0.003 0	2.346 8

6 结 论

本文基于 ITD 模糊熵和 GG 聚类分析了滚动轴承正常状态、滚动体故障、内圈故障、外圈故障以及滚动体不同损伤程度的故障, 并且隶属度在 0.97 以上。同时通过模糊熵和样本熵、近似熵对比, 结果表明模糊熵更能表征故障信号的特征信息; GG 聚类算法和 FCM、GK 聚类进行对比, 根据聚类指标表明 GG 聚类效果明显优于 FCM、GK 的聚类效果。因此本文所提出的方法对分析滚动轴承故障具有较好的效果。

参考文献

[1] 张弦, 王宏力. 进化小波消噪方法及其在滚动轴承故障诊断中的应用[J]. 机械工程学报, 2010, 46(15): 76-81.

ZHANG X, WANG H L. Evolutionary wavelet denoising and its application to ball bearing fault diagnosis [J]. Journal of Mechanical Engineering, 2010, 46(15): 76-81.

[2] 蔡剑华, 龚玉蓉, 王先春. 利用 EMD-Wigner 高阶矩谱的齿轮故障诊断方法[J]. 振动测试与诊断, 2013, 33(6): 1044-1048.

CAI J H, GONG Y R, WANG X CH. Crack fault diagnosis of gear based on EMD-Wigner higher order moment spectrum [J]. Journal of Vibration, Measurement & Diagnosis, 2010, 46(15): 76-81.

[3] 王玉静, 姜义成, 康守强, 等. 基于优化集合 EMD 的滚动轴承故障位置及性能退化程度诊断方法[J]. 仪器仪表学报, 2013, 34(8): 1834-1840.

WANG Y J, JANG Y CH, KANG SH Q, et al. Diagnosis method of fault location and performance degradation degree of rolling bearing based on optimal ensemble EMD [J]. Chinese Journal of Scientific Instrument, 2013, 34(8): 1834-1840.

[4] 王建国, 吴林峰, 秦绪华. 基于自相关分析和 LMD 的滚动轴承振动信号故障特征提取[J]. 中国机械工程, 2014, 25(2): 186-191.

WANG J G, WU L F, QIN X H. Rolling bearing vibration signal fault feature extraction based on autocorrelation analysis and LMD [J]. Chinese Journal of Mechanical Engineering, 2014, 25(2): 186-191.

[5] 姚亚夫, 张星. 基于瞬时能量熵和 SVM 的滚动轴承故障诊断[J]. 电子测量与仪器学报, 2013, 27(10): 957-962.

YAO Y F, ZHANG X. Fault diagnosis approach for roller bearing based on EMD momentary energy entropy and SVM[J]. Journal of Electronic Measurement and Instrument, 2013, 27(10): 957-962.

[6] 文莹, 肖明清, 王邑, 等. 基于信息熵属性约简的航空发动机故障诊断[J]. 仪器仪表学报, 2012, 33(8): 1773-1778.

WRN Y, XIAO M Q, WANG Y, et al. Aero-engine fault diagnosis based on information entropy attribute reduction [J]. Chinese Journal of Scientific Instrument, 2012, 33(8): 1773-1778.

[7] 袁琦, 周卫东, 李淑芳, 等. 基于 ELM 和近似熵的脑电信号检测方法[J]. 仪器仪表学报, 2012, 33(3): 514-519.

YUAN Q, ZHOU W D, LI SH F, et al. Approach of EEG detection based on ELM and approximate entropy [J]. Chinese Journal of Scientific Instrument, 2012, 33(3): 514-519.

[8] 张文斌, 郭德伟, 普亚松, 等. 谐波窗分解样本熵与灰色关联度在转子故障识别中的应用[J]. 中国电机工程


- 学报, 2013, 33(21):132-137.
- ZHANG W B, GUO D W, PU Y S, et al. Harmonic window decomposition sample entropy and grey relation degree in rotor fault recognition[J]. Proceedings of the CSEE, 2013, 33 (21): 132-137.
- [9] 张焱, 汤宝平, 邓蕾. 基于谱聚类初始化非负矩阵分解的机械故障诊断[J]. 仪器仪表学报, 2013, 34(12): 2806-2811.
- ZAHNG Y, TANG B P, DENG L. Mechanical fault diagnosis based on non-negative matrix factorization with spectral clustering initialization enhancer [J]. Chinese Journal of Scientific Instrument, 2013, 34(12): 2806-2811.
- [10] 刘慧婷, 倪志伟. 基于 EMD 与 K-means 算法的时间序列聚类[J]. 模式识别与人工智能, 2009, 22(5): 803-808.
- LIU H T, NI ZH W. Clustering method of time series based on EMD and K-means algorithm [J]. PR & AI, 2009, 22(5): 803-808.
- [11] ZARINBAL M, FAZEL ZARANDI M H, TURKSEN I B.. Relative entropy fuzzy c-means clustering [J]. Information Sciences, 2014, 260: 74-97.
- [12] LISA S, EMMANUEL R, NOUREDDINE Z. Evidential evolving Gustafson-Kessel algorithm for online data streams partitioning using belief function theory [J]. International Journal of Approximate Reasoning ,2012, 53(5): 747-768.
- [13] 胥永刚, 谢志聪, 崔玲丽, 等. 基于 ITD 的齿轮磁记忆信号特征提取方法的研究[J]. 仪器仪表学报, 2013, 34(3): 672-676.
- XU Y G, XIE ZH C, CUI L L, et al. Study on feature extraction method of gear magnetic memory signal based on ITD [J]. Chinese Journal of Scientific Instrument, 2013, 34(3): 672-676.
- [14] 邓艾东, 赵力, 包永强. 基于模糊熵的转子碰摩声发射信号的识别[J]. 机械工程学报, 2010, 46(3): 71-75.
- DENG AI D, ZHAO L, BAO Y Q. Recognition of rub-impact acoustic emission signal based on fuzzy entropy[J]. Journal of Mechanical Engineering, 2010, 46 (3): 71-75.
- [15] 王书涛, 张金梅, 李圆圆, 等. 基于数学形态学和模糊聚类的旋转机械故障诊断[J]. 仪器仪表学报, 2012, 33 (5): 1056-1061.
- WANG SH T, ZHANG J M, LI Y Y, et al. Rotating machinery fault diagnosis based on mathematical morphology and fuzzy clustering[J]. Chinese Journal of Scientific Instrument, 2012, 33(5): 1056-1061.

作者简介



张立国, 2010 年于燕山大学获得博士学位, 现为燕山大学副教授, 硕士生导师, 主要研究方向为故障诊断、机器运动感知、虚拟现实等。
E-mail: zlgtime@163.com

Zhang Liguang received doctor degree from Yanshan University in 2010. Now he is an associate professor in Yanshan University. His research areas include fault diagnosis, machine motion perception and virtual reality technology, etc.



李盼 (通讯作者), 燕山大学博士研究生, 主要研究方为信号检测和故障诊断。
E-mail: lpanysu@163.com

Li Pan (Corresponding author) is a doctor student in Yanshan University. His research interests include signal detection and fault diagnosis.



李梅梅, 东北大学秦皇岛分校实验员, 主要研究方为弱信号处理和故障诊断。
E-mail: 240844165@qq.com

Li Meimei is a laboratory technician in Northeastern University at Qinhuangdao. Her research areas include weak-signal processing and fault diagnosis.